# Krzysztof Sekuła

Sprawozdanie z projektu nr 3

Celem ćwiczenia było poznanie budowy i działania wielowarstwowych sieci neuronowych poprzez uczenie z użyciem algorytmu wstecznej propagacji błędu rozpoznawania konkretnych liter alfabetu.

# **Opis budowy algorytmu:**

Podobnie jak w przypadku pojedynczego neuronu, główną zaletą sieci neuronowej jest to, że nie musimy "ręcznie" dobierać wag. Możemy te wagi wytrenować, czyli znaleźć ich w przybliżeniu optymalny zestaw za pomocą metody obliczeniowej zwanej wsteczną propagacją błędu. Jest to metoda umożliwiająca modyfikację wag w sieci o architekturze warstwowej we wszystkich jej warstwach.

Ogólny schemat procesu uczenia sieci wygląda następująco:

- Ustalamy topologię sieci, tzn. liczbę warstw, liczbę neuronów w warstwach.
- 2. Inicjujemy wagi losowo
- 3. Dla danego wektora uczącego obliczamy odpowiedź sieci warstwa po warstwie
- 4. Każdy neuron wyjściowy oblicza swój błąd, oparty na różnicy pomiędzy obliczoną odpowiedzią *y* oraz poprawną odpowiedzią *t*
- 5. Błędy propagowane są do wcześniejszych warstw
- 6. Każdy neuron ,również w warstwach ukrytych modyfikuje wagi na podstawie wartości błędu i wielkości przetwarzanych w tym kroku sygnałów
- 7. Powtarzamy od punktu 3 dla kolejnych wektorów uczących. Gdy wszystkie wektory zostaną użyte, losowo zmieniamy ich kolejność i zaczynamy wykorzystywać powtórnie.
- 8. Zatrzymujemy się, gdy średni błąd na danych treningowych przestanie maleć. Możemy też co jakiś czas testować sieć na specjalnej puli nieużywanych do treningu próbek testowych i kończyć trenowanie, gdy błąd przestanie maleć.

# Zestawienie wyników:

Jako dane uczące wykorzystałem 20 liter, 10 dużych oraz 10 małych, w postaci dwuwymiarowej tablicy 4x5. Testy przeprowadziłem 10 razy dla trzech różnych współczynników uczenia.

LP	Współczynnik uczenia	0,1	0,01	0,001
1	ilość iteracji:	42364	30584	245719
2	ilość iteracji:	23464	38358	167344
3	ilość iteracji:	43603	87876	345743
4	ilość iteracji:	31580	80608	261660
5	ilość iteracji:	13438	29538	215930
6	ilość iteracji:	45567	53568	156420
7	ilość iteracji:	51409	83095	397260
8	ilość iteracji:	25026	35864	241184
9	ilość iteracji:	21772	39555	318800
10	ilość iteracji:	18426	21944	197165

Współczynnik uczenia	Średnia ilość iteracji	
0,1	31664,9	
0,01	50099	
0,001	254722,5	



Przykładowy wynik dla współczynnika uczenia 0.01:

## Wejsciowy wektor: 8

```
-0,07, -0,07, -0,07, -0,06, -0,07, -0,06, -0,06, 0,94, -0,07, -0,06, -0,06, -0,05, -0,07, -0,07, -0,05, -0,08, -0,07, -0,05, -0,08,
```

## Wynik oczekiwany:

#### Wnioski:

Z otrzymanych wyników możemy wnioskować że współczynnik uczenia wpływa na szybkość uczenia jak i na poprawność wyników. Dla współczynnika 0.1 ilość iteracji potrzebnych do nauczenia sieci była najmniejsza. Im mniejszy współczynnik tym ilość iteracji rosła, natomiast zmniejszał się błąd.

# Listing kodu:

```
public class Main {
    private static int n = 20;
    private static double e = 2.718281828459045235;

public static void main(String[] args) {

    Random rand = new Random();
    double[][] all = new double[n][n];
    double[][] answers = new double[20][5];
    double[] firstLayerAnswers = new double[n];
    double[] secondLayerAnswers = new double[5];
    double[] thirdLayerAnswers = new double[n];
    double[] errors;
    double learningRate = 0.001;
        createWectors(all);
        setAnswerVectors(answers);
        double error = 0;
        int ni = 0;
        Perc2[] firstLayer = new Perc1[n];
        Perc2[] secondLayer = new Perc2[s];
        perc2[] thirdLayer = new Perc2[n];
        java.text.DecimalFormat df = new java.text.DecimalFormat();
        df.setMaximumFractionDigits(2);
        for (int i = 0; i < 20; i++) {
            firstLayer[i] = new Perc1();
        }
}</pre>
```

```
thirdLayer[i] = new Perc2(5);
                firstLayerAnswers[i] = 1 / (1 + Math.pow(e, -
firstLayer[i].sum());
            setVectorsSecondLayer(firstLayerAnswers, secondLayer);
secondLayer[i].sum()));
            setVectorsThirdLayer(secondLayerAnswers, thirdLayer);
                thirdLayerAnswers[i] = 1 / (1 + Math.pow(e, -
thirdLayer[i].sum());
               errors[i] = answers[which][i] - thirdLayerAnswers[i];
thirdLayer[j].getWeights()[i];
                    macierzBledowW1[j] += macierzBledowW2[i] *
secondLayer[i].getWeights()[j];
Math.pow((Math.pow(e, firstLayer[i].getSuma()) + 1), 2));
```

```
Math.pow((Math.pow(e, secondLayer[i].getSuma()) + 1), 2))
                            * firstLayerAnswers[j];
Math.pow((Math.pow(e, thirdLayer[i].getSuma()) + 1), 2));
                    thirdLayer[i].setWeight(j, newWeight);
                firstLayerAnswers[i] = 1 / (1 + Math.pow(e, -
firstLayer[i].sum());
            setVectorsSecondLayer(firstLayerAnswers, secondLayer);
secondLayer[i].sum()));
            setVectorsThirdLayer(secondLayerAnswers, thirdLayer);
                thirdLayerAnswers[i] = 1 / (1 + Math.pow(e, -
thirdLayer[i].sum());
                errors[i] = answers[which][i] - thirdLayerAnswers[i];
                System.out.print(df.format(errors[i]) + ", ");
```

```
private static void setVectorsThirdLayer(double[] secondLayerAnswers,
Perc2[] thirdLayer) {
            thirdLayer[i].setVector(secondLayerAnswers);
        answers[11] = row11;
        answers[14] = row14;
```

```
private static void setVectorsSecondLayer(double[] firstLayerAnswers,
Perc2[] secondLayer) {
            secondLayer[i].setVector(firstLayerAnswers);
```

```
all[0] = A;
all[1] = B;
all[2] = C;
all[3] = D;
all[4] = E;
all[5] = F;
all[6] = G;
all[7] = H;
all[8] = I;
all[9] = J;
all[10] = a;
all[11] = b;
all[12] = c;
all[13] = d;
all[14] = e;
all[15] = f;
all[16] = g;
all[17] = h;
all[18] = i;
all[19] = j;
}

public static int setVectorsFirstLayer(Percl[] firstLayer, double[][]
all, Random rand) {
   int wejscie = rand.nextInt(20);
   System.out.println("Wejsciowy wektor: " + wejscie);
   for (int i = 0; i < 20; i++) {
        double wl = all[wejscie][i];
        firstLayer[i].setVariable(wl);
   }

   return wejscie;
}</pre>
```

#### Źródła:

http://edu.pjwstk.edu.pl/wyklady/nai/scb/wyklad3/w3.htm